Análisis predictivo del mercado inmobiliario uruguayo

Florencia Barrios
María Ines Martinote
Florencia Lucas

Contexto

- **Problema**: Es difícil para un comprador evaluar objetivamente si un apartamento listado está a precio de mercado o si es una verdadera oportunidad.
- **Datos**: 550 mil publicaciones de ventas de apartamentos en Uruguay
- **Fuentes**: Gallito y Mercado Libre
- **Periodo**: 2023-2025 (Gallito solo comprende datos de 2023)

Objetivo:

Predecir el precio de apartamentos en Uruguay a partir de características y atributos obtenidos mediante web scraping de las principales páginas inmobiliarias.

Preguntas clave:

- ¿Cuáles son las principales variables que inciden en el precio?
- ¿Hay diferencias en el precio promedio entre Meli y Gallito?
- ¿Cuáles son las localidades más caras y más baratas?
- ¿Existe multicolinealidad entre las variables independientes?

Limpieza de datos

Dataset original:

- 550,428 registros y 33 columnas
- 25 variables object y 8 numéricas
- Variable objetivo: Precio

	count	mean	std	min	25%	50%	75%	max
COVERED_AREA	178909.00	133.25	3253.64	0.00	45.00	63.00	95.00	620000.00
ROOMS	179636.00	0.61	1.35	-2.00	0.00	0.00	0.00	117.00
TOTAL_AREA	51799.00	120.90	1652.68	0.00	48.00	66.00	100.00	245648.00
PRICE	179636.00	258579.97	1114566.94	1.00	125000.00	169000.00	280000.00	444444444.00
FULL_BATHROOMS	179204.00	1.61	2.12	0.00	1.00	1.00	2.00	235.00
BEDROOMS	165764.00	1.97	1.02	0.00	1.00	2.00	3.00	116.00
ARTICLE_ID	127405.00	22818793.24	1872309.50	11035467.00	22247480.00	23464550.00	24106859.00	24832554.00
GARAGE	179636.00	0.34	1.10	0.00	0.00	0.00	1.00	255.00
CONSTRUCTION_YEAR	31909.00	1980.78	346.24	1.00	1976.00	2010.00	2022.00	19701.00

Tratamiento de datos:

- Registros duplicados. Nos quedamos con 145,505 filas únicas
- Conversión de formatos: precio, fecha y variables dummies
- Unificación de variables duplicadas por distintas fuente de datos (por ejemplo ADDRES_CITY_NAME Y NEIGHBORHOOD)
- Eliminación de variables irrelevantes
- Missings: exclusión de variables con alto porcentaje de valores faltantes
- Outliers: eliminación de valores incoherentes y atípicos para no distorsionar el análisis (como precios y áreas en percentiles extremos)

Feature Engineering

- Antiguedad: generada a partir del año de construcción
- Localidad: limpieza y agrupación por municipios (fuente: censo 2023) y departamentos.
- Condición agrupada
- Dummies a partir de palabras clave en las descripciones (ej. garage, amenities, al frente)
- Creación de ratio baños/dormitorios

muni_depto	count
Maldonado	34005
Municipio B	30752
Municipio CH	24252
Municipio E	7485
Municipio C	4354
Canelones	1588
Municipio D	1427
Otros	689
Municipio G	399
Municipio A	377
Otra	301
Municipio F	138
Colonia	78
Flores	55
Paysandu	21
Cerro Largo	20
otros	19
Soriano	15

	mean
dummy_amenities	0.33
dummy_lujo	0.13
dummy_vistas	0.37
dummy_frente	0.25
dummy_contrafrente	0.06
dummy_exterior	0.43
dummy_nuevo	0.24
dummy_en_pozo	0.02
dummy_piscina	0.10
dummy_interior	0.07
dummy_lateral	0.02
dummy_reciclado	0.03
dummy_a_reciclar	0.00
dummy_pozo_aire	0.00
dummy_garage	0.31

Análisis Exploratorio

- Univariado
- Bivariado
- Multivariado

Análisis Univariado

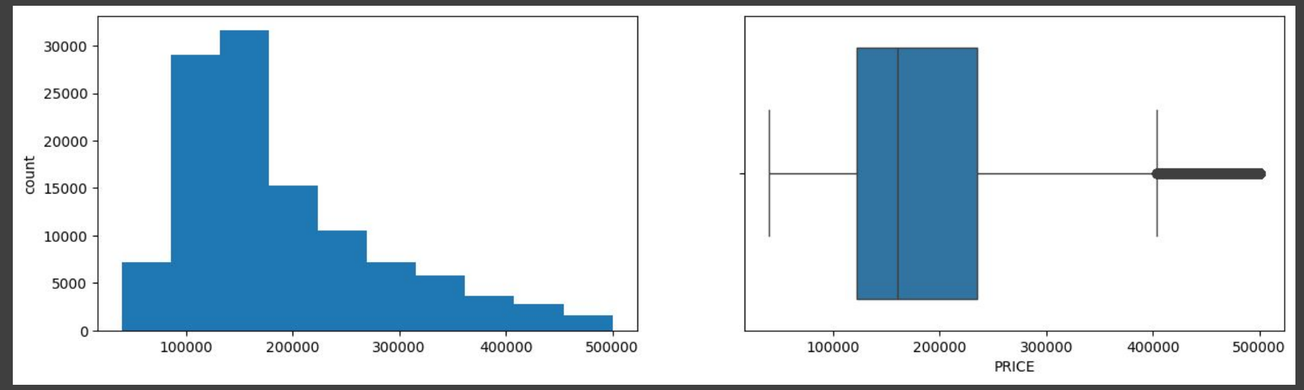

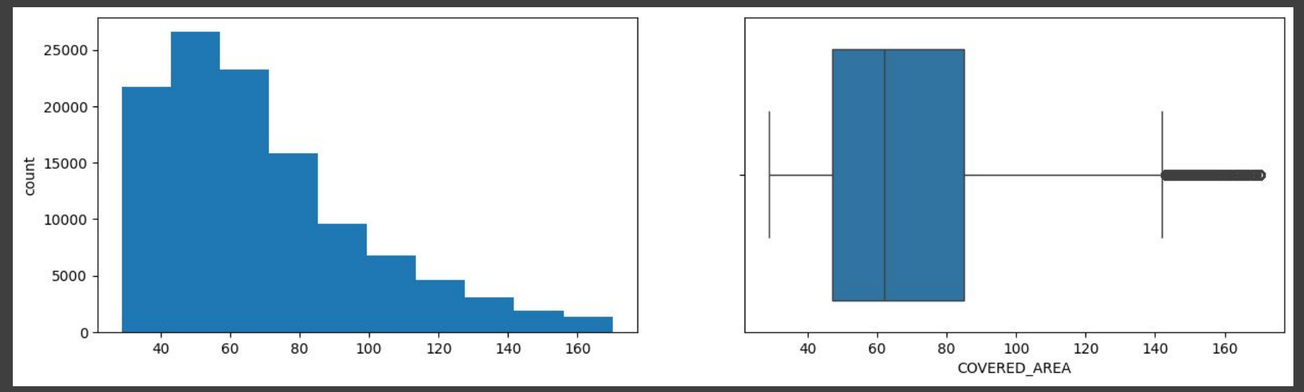

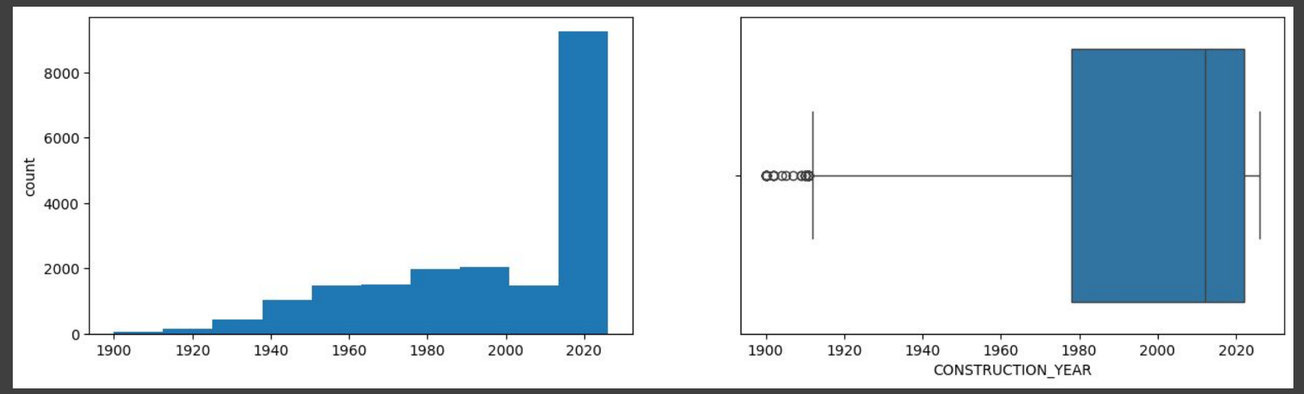

- La gran mayoría de la oferta de apartamentos se concentra en propiedades de precio y superficie bajos/medios. Existe una cola larga de pocas propiedades muy caras y muy grandes.

- A diferencia del precio el año de construcción tiene un sesgo a la izquierda, es decir, mayor cantidad de construcciones más recientes.

Análisis Bivariado

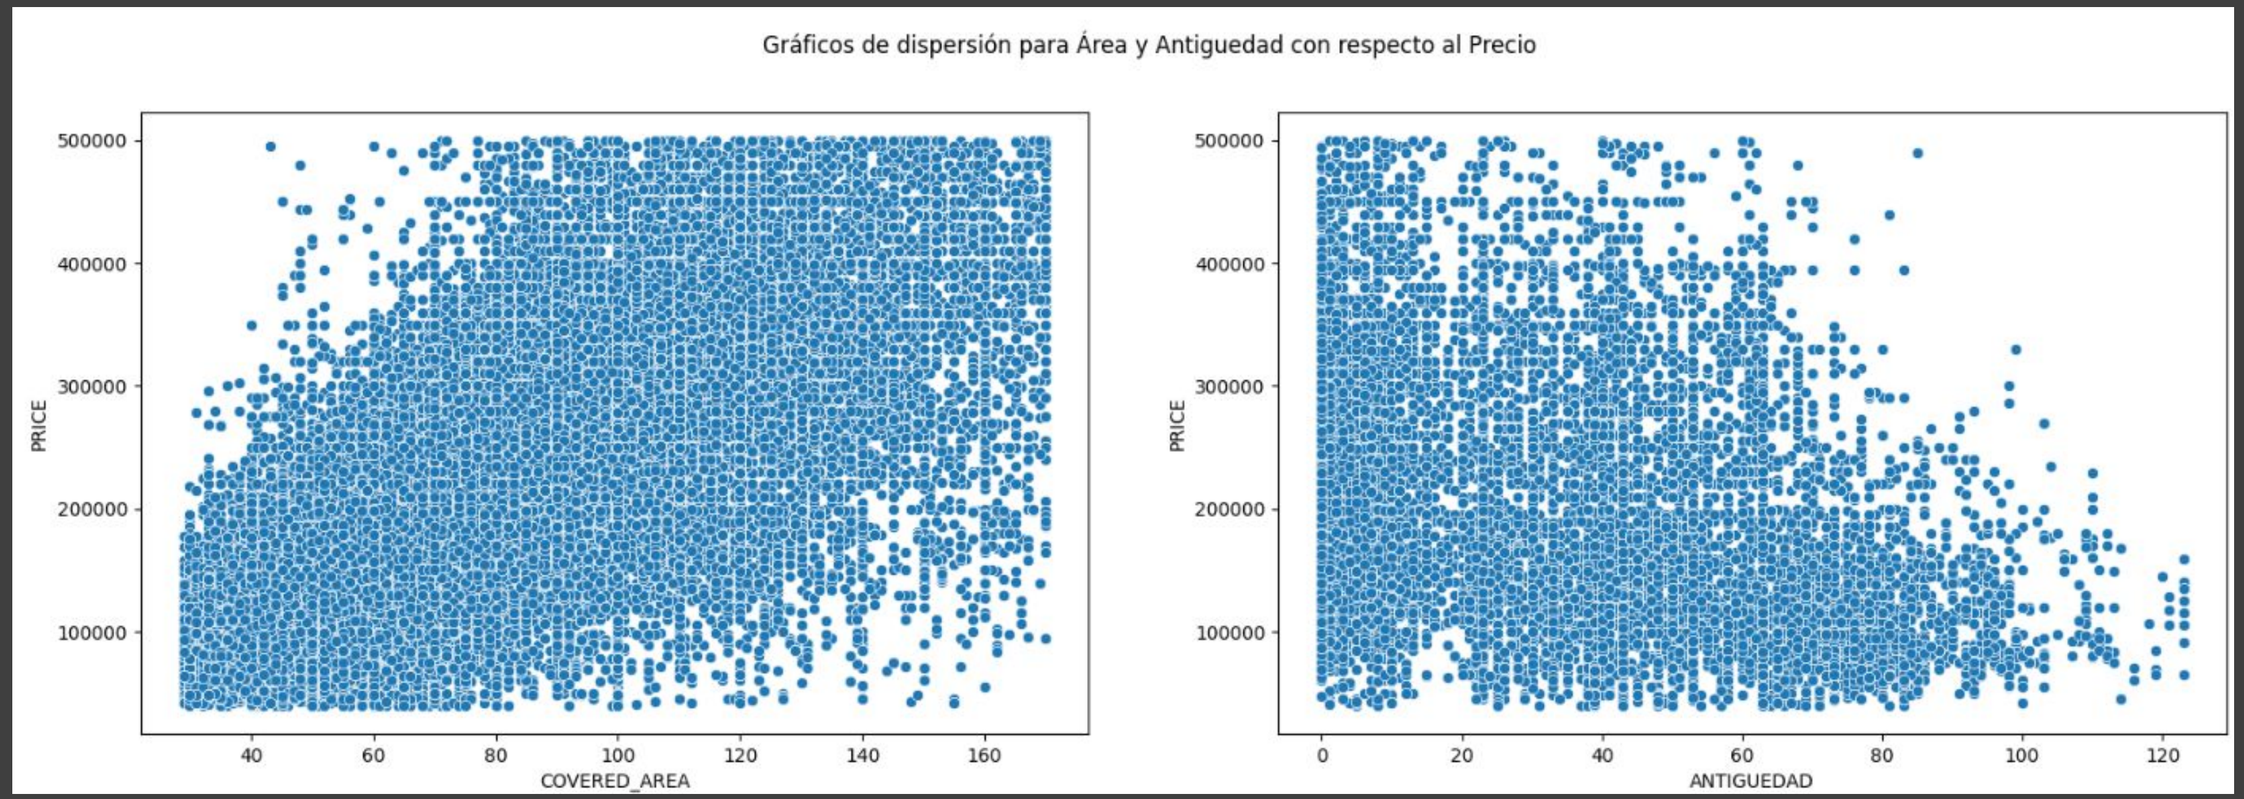

- Se observa una relación positiva entre el área cubierta y el precio. La concentración de puntos en la parte inferior izquierda indica que la mayoría de los apartamentos son más pequeños y menos costosos.

- Se aprecia una relación inversa entre antigüedad y precio. Los apartamentos más nuevos tienden a tener precios más altos, mientras que los apartamentos con mayor antigüedad generalmente tienen precios más bajos.

Localidades

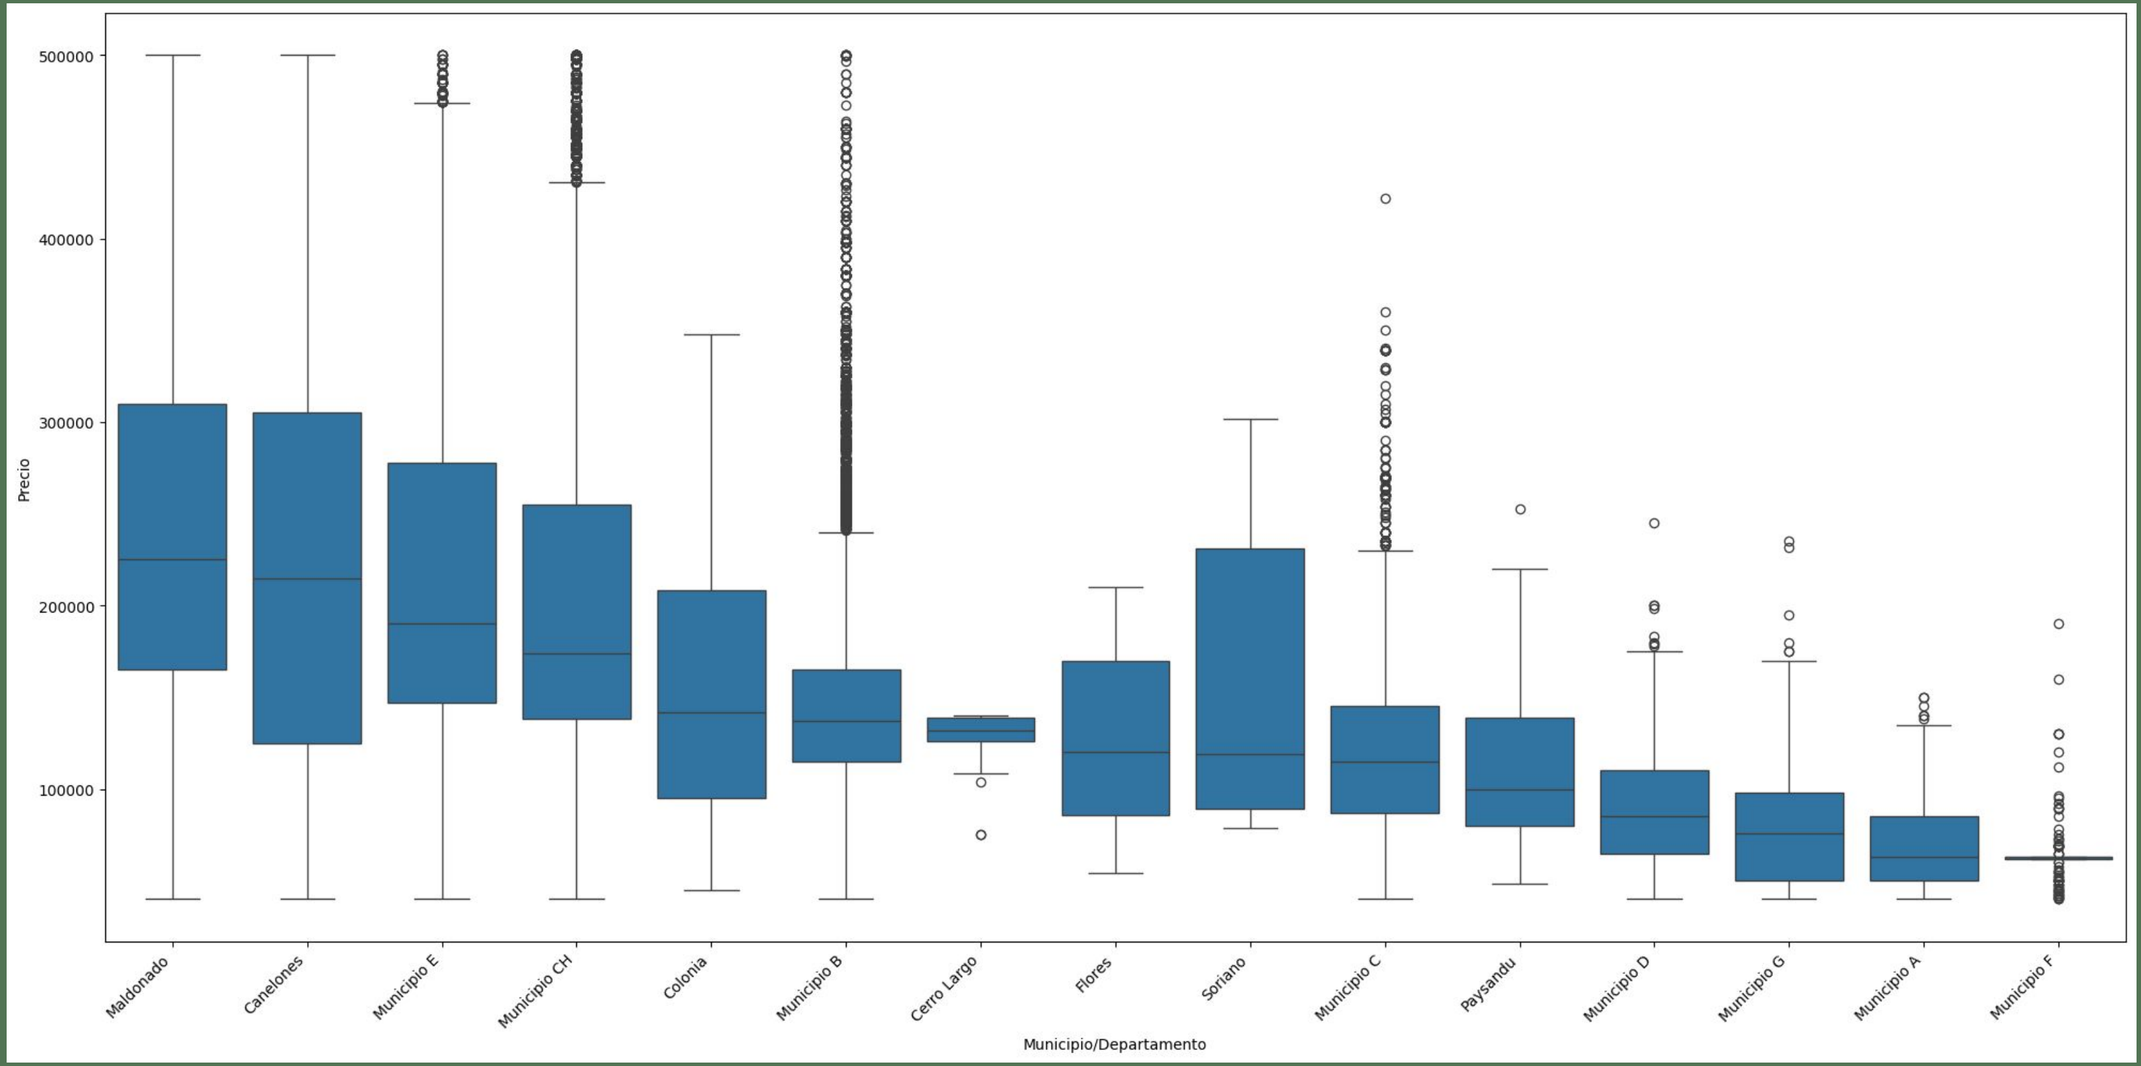

- Maldonado tiene los apartamentos en venta más caros en promedio. Canelones le sigue, aunque con mayor dispersión en los precios.
- Los municipios E (Carrasco, Malvin, Punta Gorda) y CH (Pocitos y Punta Carretas) presentan los precios más altos dentro de Montevideo.
- El municipio F (Flor de Maroñas, Jardines del Hipódromo, Manga) es el más accesible.

Dummies

- La mayoría de los boxplots muestran diferencias en los precios entre los apartamentos que poseen la característica y los que no
- Posiciones como contrafrente, lateral e interior tienen precios más bajos en promedio
- Apartamentos con pozo de aire, a reciclar o en pozo, también suelen ser más baratos
- Aquellos con garage y/o piscina son notoriamente más caros que los que no tienen

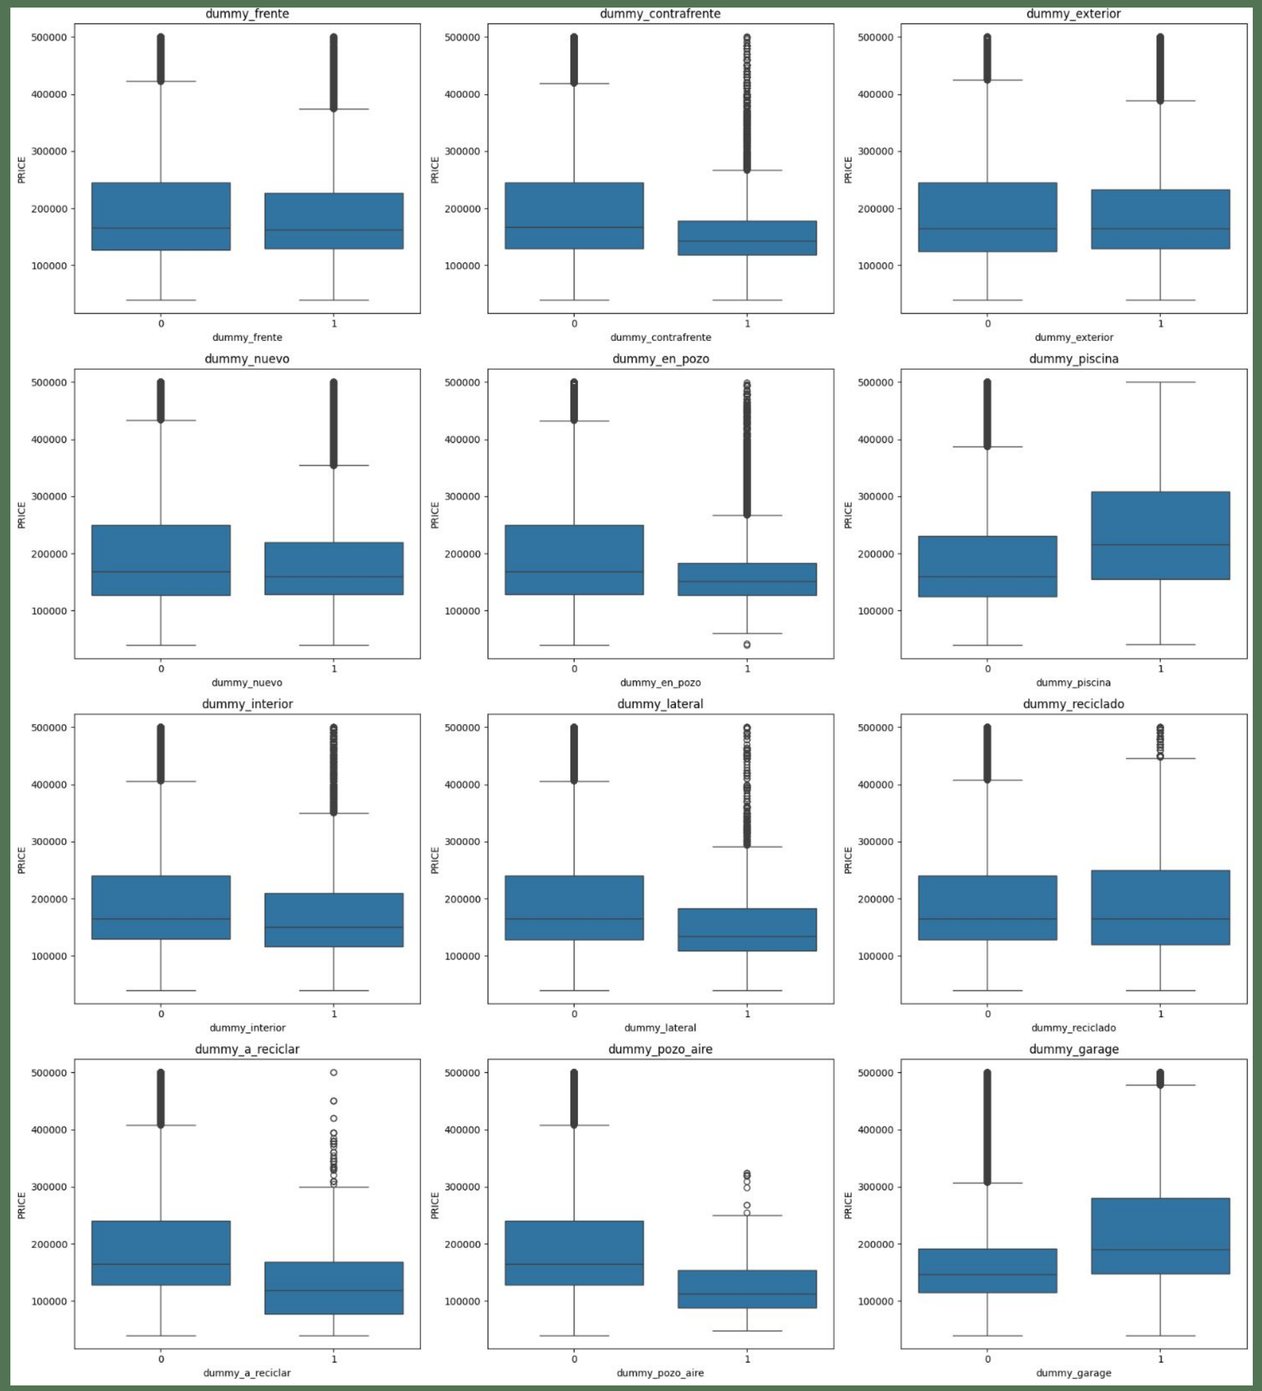

Matriz de Correlaciones

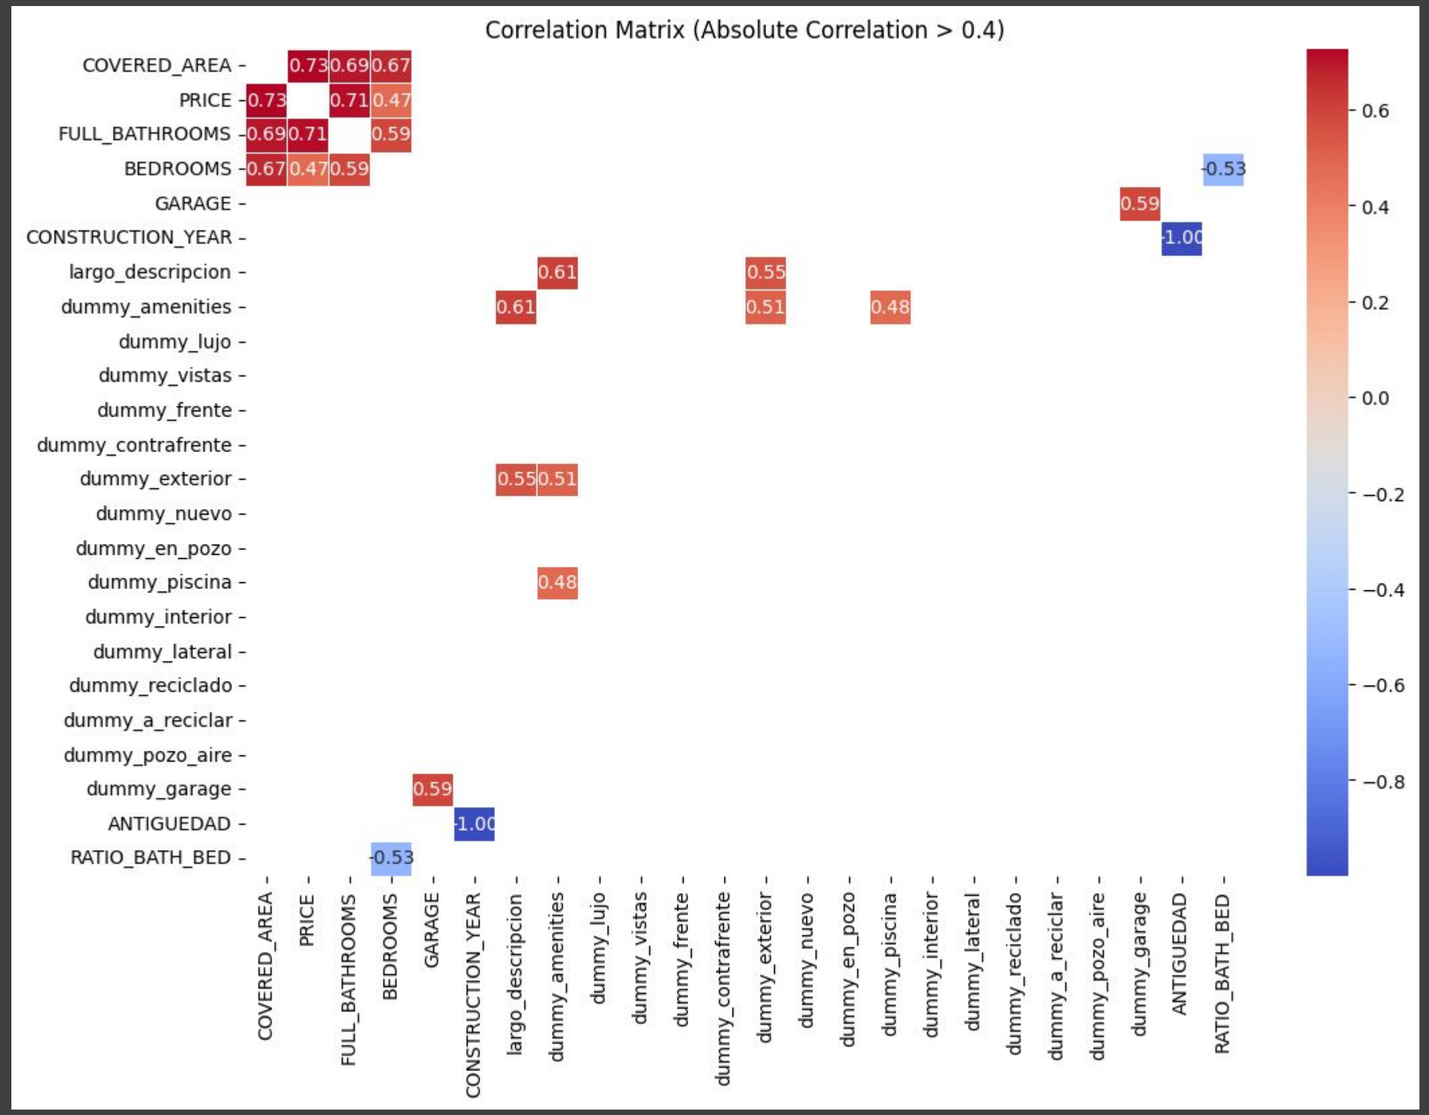

Correlaciones fuertes con precio

- Área cubierta (0.73)
- Cantidad de baños (0.71)
- Cantidad de dormitorios (0.47)

Correlaciones entre variables independientes

- Área cubierta con cantidad de baños (0.73)
- Cantidad de dormitorios con cantidad de baños (0.59)
- Área cubierta con garage (0.67)

Desarrollo de modelos

Preparación de los datos para el modelo

Árbol de decisión, Random Forest, XGBoost y AdaBoost

- Eliminación de variables con alto porcentaje de missings (sustituidas por dummies creadas en la etapa anterior)
- Aplicación de One-Hot Encoding a muni_depto
- Separación de variables independientes de la target
- Separación del dataset en train (80%) y test (20%)

CatBoost

- No eliminamos variables solo por tener missings, ya que maneja los valores nulos de forma nativa.
- Identificación de variables categóricas, dado que las trata de forma diferencial (muni_depto y POSITION)
- Separación de variables independientes de la target
- Separación del dataset en train (80%) y test (20%)

Modelos utilizados 🚩

- **Árbol de decisión**: tiene una desviación porcentual promedio de 17.19% y como primer modelo es un buen resultado
- **XGBoost y CatBoost:** presentan mejor comportamiento que el árbol de decisión pero no superan al Random forest
- **AdaBoost:** peor desempeño, muy sensible a outliers y al ruido
- **Random Forest: mayor precisión y mejor ajuste (mejor modelo)**

Test performance comparison:

	RMSE	MAE	R-squared	Adj. R-squared	MAPE
Decision tree regressor	50109.37	30582.39	0.72	0.71	17.19
Random Forest regressor	43194.92	28180.64	0.79	0.79	16.08
Ada Boost Regressor	58227.17	44610.93	0.62	0.61	29.28
XG Boost Regressor	45737.11	32476.25	0.76	0.76	18.57
CatBoost Regressor	46866.05	33583.21	0.75	0.75	19.22

Interpretación MAPE Random Forest:

- Si el precio real de un apartamento es de USD 200,000, el modelo de Random Forest se va a equivocar, en promedio, en un 16.08%.
- $200,000 * 0.1608 = USD 32,160
- La predicción estaría entre USD 167,840 y USD 232,160.

Optimización de hiperparámetros con optuna

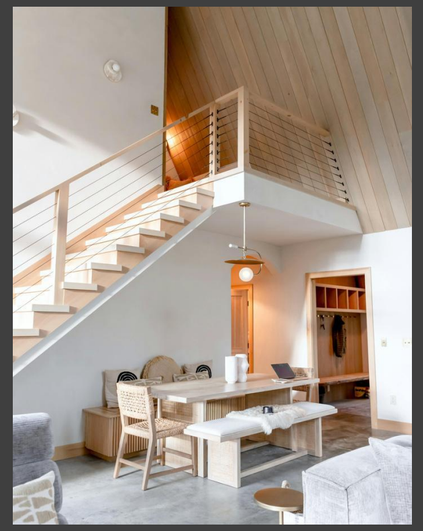

Mejores Hiperparámetros:

- Número de árboles (250) → **Estabilidad**
- Profundidad máxima de cada árbol (25) → **Control de Overfitting**
- Mínimo de muestras para dividir un nodo (2) → **Precisión**
- Número de características a considerar en cada división (0.3) → **Diversidad y aleatoriedad**
- Evaluamos el modelo usando validación cruzada (**robustez**) y MAPE (**relevancia para el negocio**)
- Número de trials: 50 → b**alance entre profundidad y costo computacional**

	RMSE	MAE	R-squared	Adj. R-squared	MAPE
0	42281.67	27861.47	0.80	0.80	15.90

Notamos una mejora con respecto al modelo original:

- El MAPE disminuye de 16.08 a 15.90
- El MAE disminuye de 28,180.64 a 27,861.47
- El R cuadrado aumenta de 0.79 a 0.80

Árbol de decisión vs Random Forest

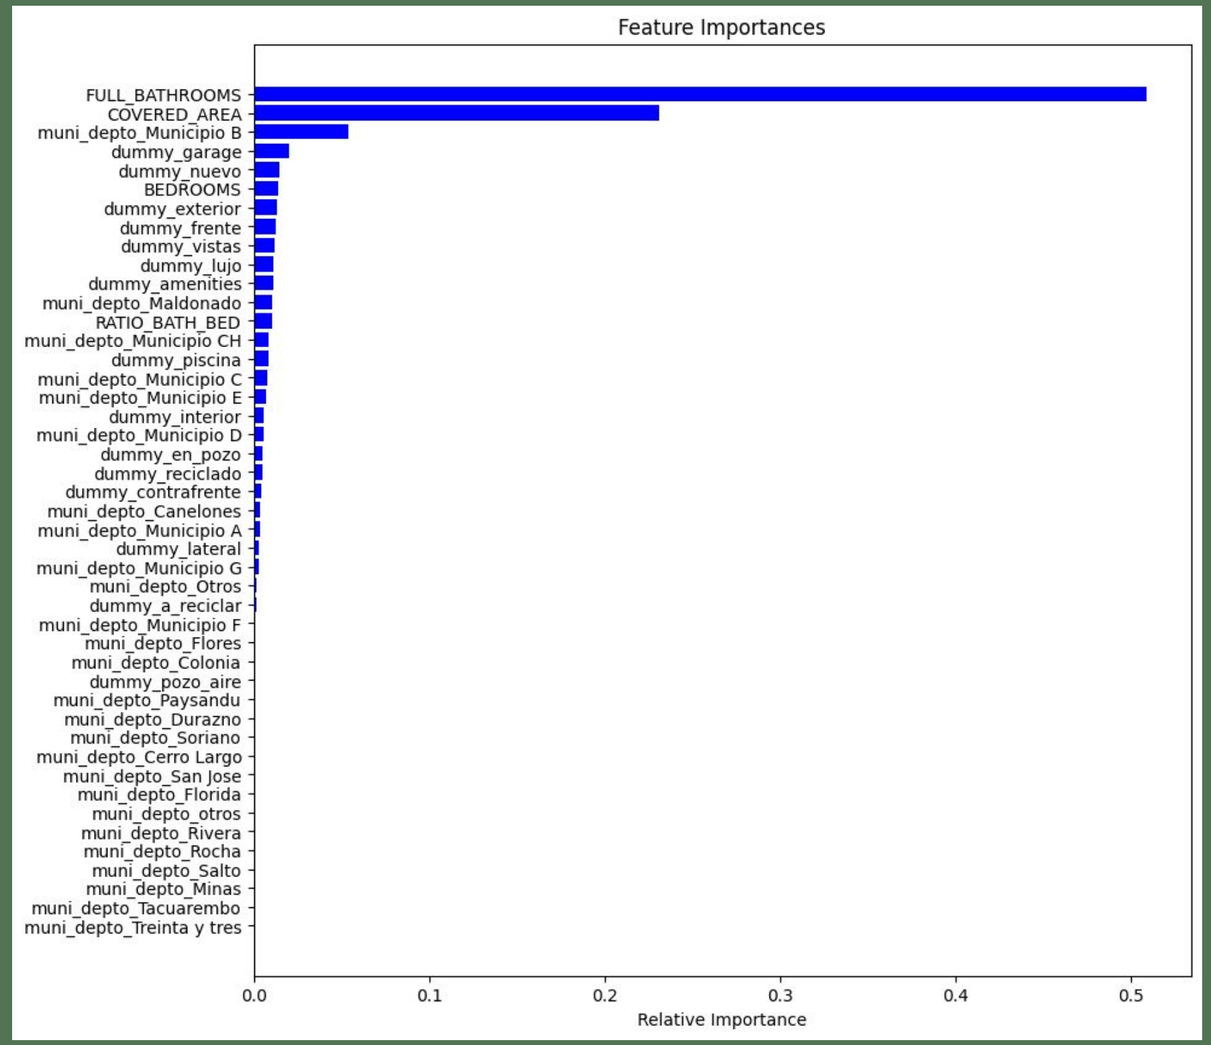

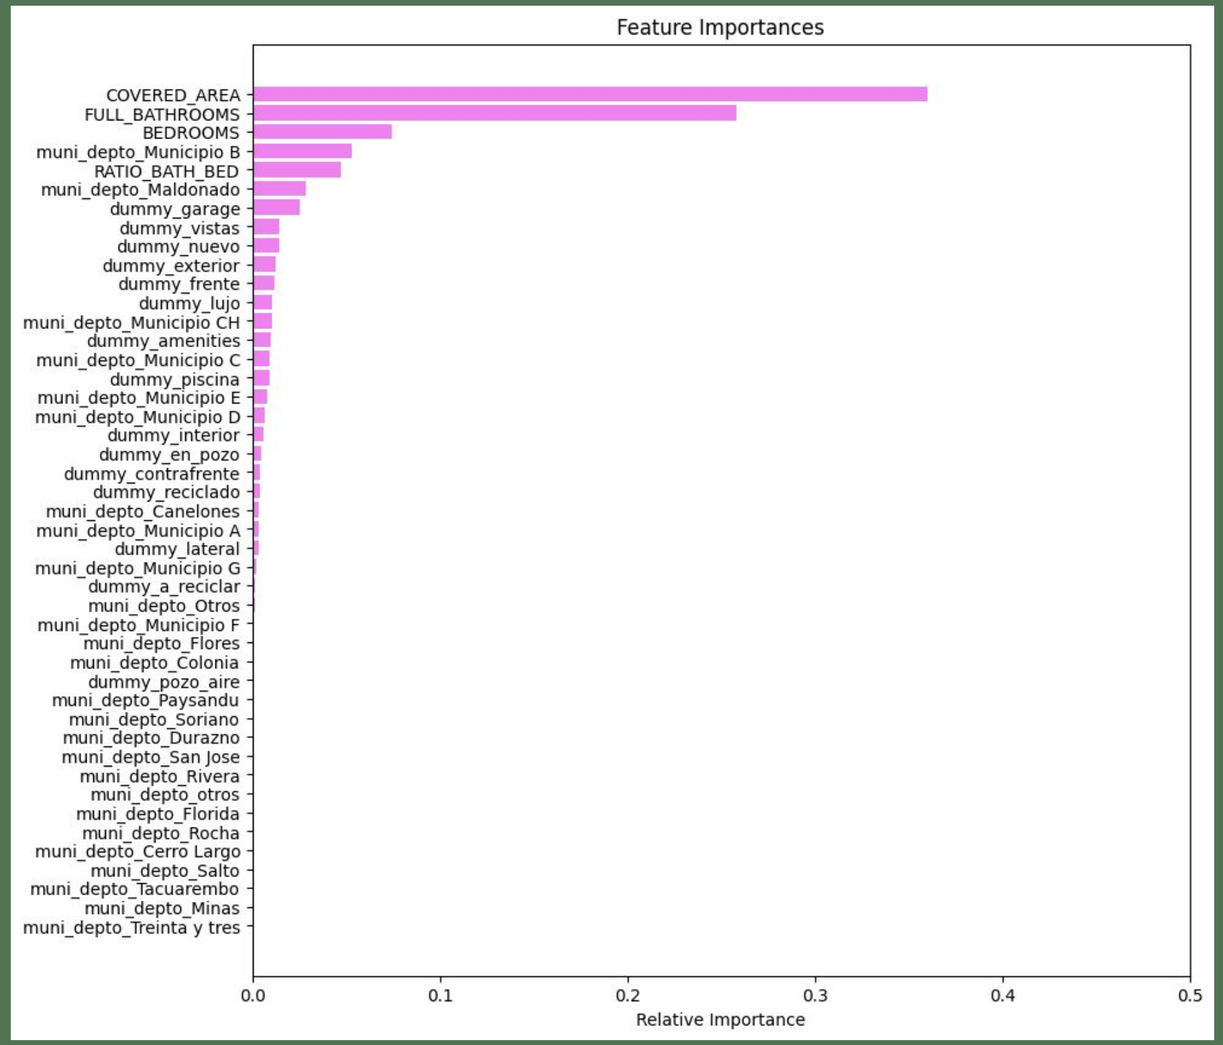

- La importancia está más distribuida en el Random Forest, esto indica mayor robustez y generalización
- Las variables más relevantes se mantienen. Se incrementa la importancia de dormitorios

Resultados:

Random forest con optimización

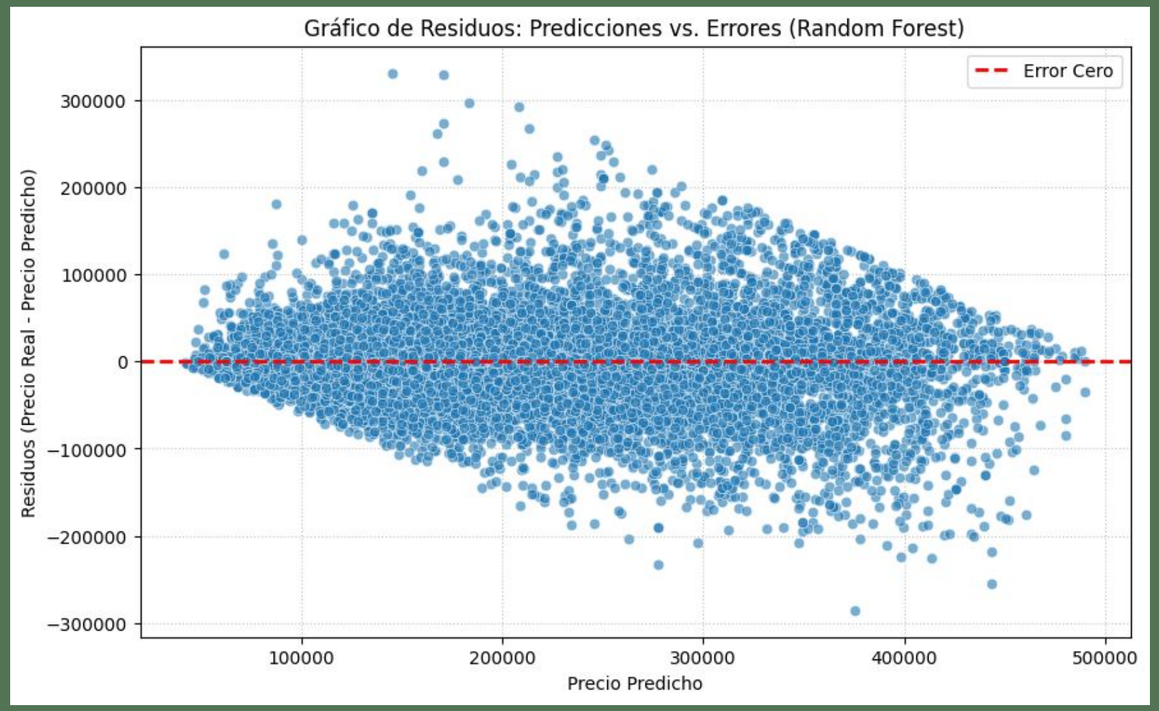

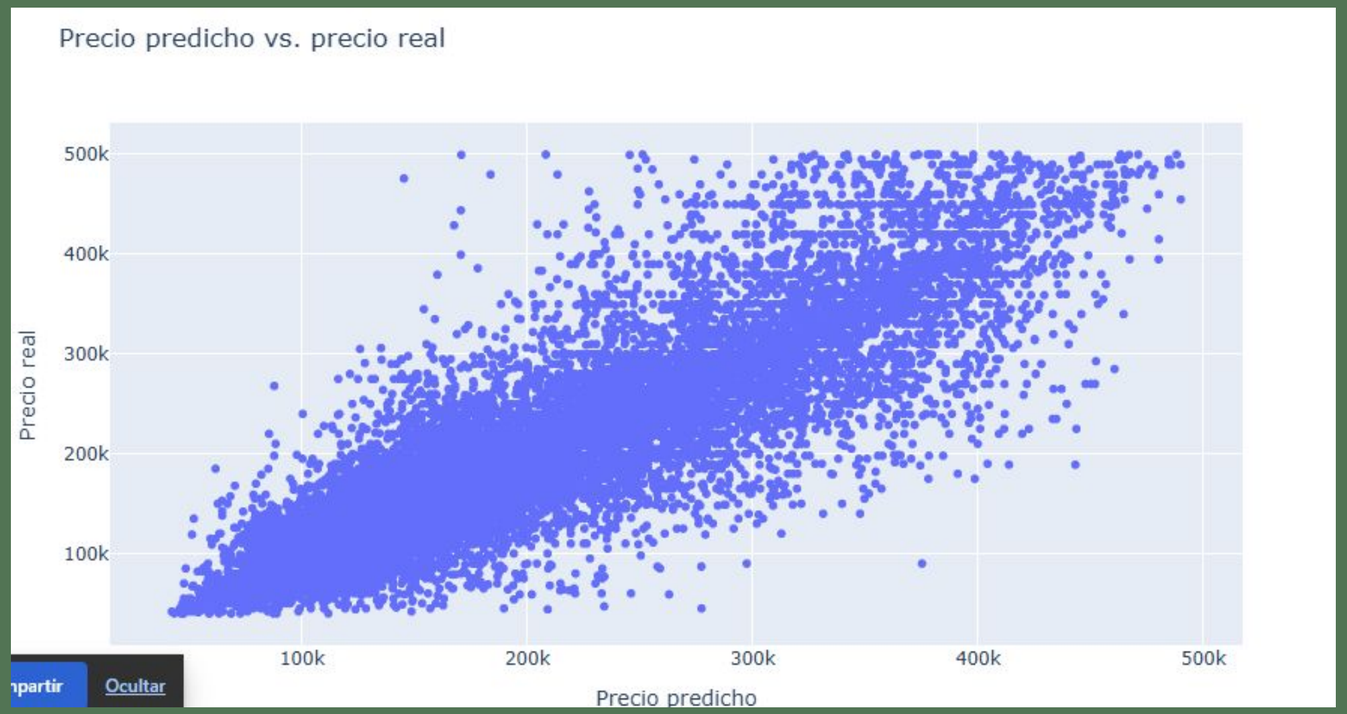

- En precios más bajos el modelo es preciso, en precios del "medio" la nube de puntos se ensancha y en valores más altos el modelo tiende a sobrestimar los precios.

- Correlación lineal positiva entre el precio predicho y el precio real
- El random forest predice promediando precios por lo cual nunca va a predecir valores que no haya visto (es decir por encima de USD 500k o por debajo de USD 40k)

Principales Conclusiones

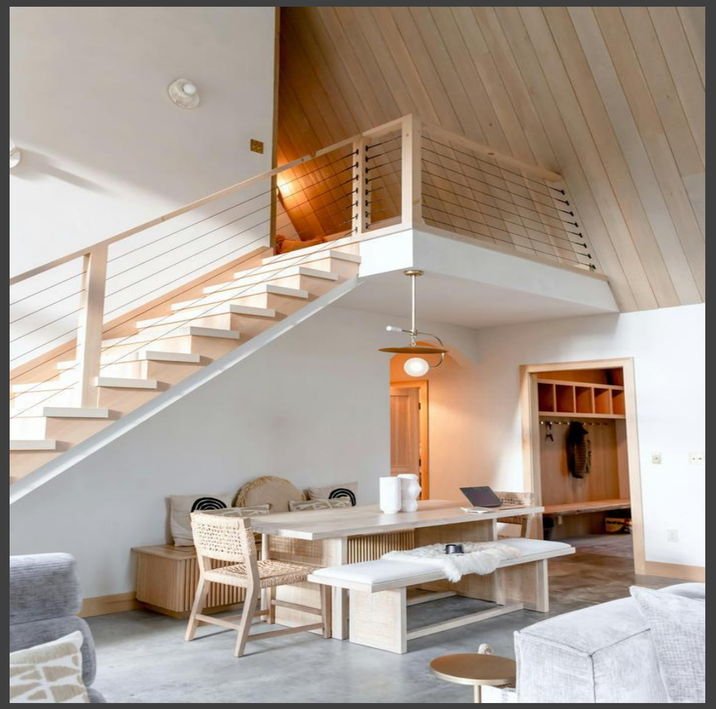

1

Efectividad Comprobada: El Random Forest optimizado es altamente efectivo, cumpliendo el objetivo de predecir precios de apartamentos.

2

Próximo Paso: Se requiere validación con datos más **recientes** para confirmar la solidez y vigencia del modelo ante posibles cambios en el mercado inmobiliario.

3

Recomendación Estratégica: Implementar como sistema de tasación automatizada en tiempo real. Esto podría permitir a inmobiliarias e inversores generar cotizaciones iniciales de forma instantánea.